

Guía general del proyecto

Proyecto Integrador - README

Autor: Matias Damian Gutierrez

Fecha: 10/15/2025

INDICE

FleetLogix - Sistema de Gestión de Flotas y Data Warehouse

Descripción del Proyecto

Objetivos del Proyecto

Arquitectura del Sistema

Componentes Principales

Métricas y Resultados

Tecnologías Implementadas

Estructura del Proyecto

Características Destacadas

Lecciones Aprendidas

Próximos Pasos Recomendados

Autor

FleetLogix - Sistema de Gestión de Flotas y Data Warehouse

Descripción del Proyecto

FleetLogix es un sistema integral de gestión de flotas vehiculares y análisis de datos diseñado específicamente para operaciones logísticas en Argentina. El proyecto abarca desde la base de datos transaccional hasta un Data Warehouse analítico en Snowflake, implementando mejores prácticas de ingeniería de datos y arquitectura cloud.

Objetivos del Proyecto

- Migrar de un sistema transaccional PostgreSQL a un Data Warehouse analítico en Snowflake
- Implementar un pipeline ETL robusto y automatizado
- Garantizar la calidad e integridad de los datos mediante validaciones exhaustivas
- Optimizar el performance de consultas para reporting ejecutivo
- Diseñar una arquitectura escalable en AWS para operaciones en tiempo real

Arquitectura del Sistema

Componentes Principales

Base de Datos Transaccional (PostgreSQL)

- 7 tablas principales diseñadas para operaciones logísticas
- 506,650 registros sintéticos generados
- Modelo híbrido transaccional-dimensional
- SCD Type 2 para tracking histórico en vehículos y conductores

Data Warehouse (Snowflake)

- Modelo estrella con FACT_DELIVERIES como tabla de hechos
- Dimensiones: fecha, vehículo, conductor, ruta, cliente
- Pipeline ETL automatizado en Python
- Estrategia UPSERT dual para prevenir duplicados

Arquitectura AWS (Propuesta)

- RDS PostgreSQL para datos históricos
- DynamoDB para operaciones en tiempo real
- Lambda Functions para procesamiento serverless
- S3 para almacenamiento y backups

Métricas y Resultados

Volúmenes de Datos

- Vehículos: 200 registros
- Conductores: 400 registros
- Viajes: 100,000 registros
- Entregas: 400,000 registros
- Clientes: 1,000 registros

Performance ETL

- Tiempo ejecución: 48-49 segundos (proceso completo)
- Registros procesados: 1,898 sin duplicados
- Eficiencia UPSERT: 100% de integridad referencial

Métricas de Negocio

- Entregas a tiempo: 32.9%
- Eficiencia combustible: 2.7 km/L
- Rentabilidad analizada: \$289,075.88

Tecnologías Implementadas

Backend y Base de Datos

- PostgreSQL 15.4 - Base de datos transaccional
- Snowflake - Data Warehouse analítico
- Python 3.8+ - Pipeline ETL y generación de datos
- SQLAlchemy - ORM y conexiones a bases de datos

Librerías Python Principales

- Pandas - Manipulación y transformación de datos
- Faker - Generación de datos sintéticos realistas
- NumPy - Distribuciones probabilísticas avanzadas
- Boto3 - Integración con AWS (simulada)

Arquitectura Data

- Modelo Dimensional - Esquema estrella optimizado para análisis
- ETL Automatizado - Pipeline en Python con logging completo
- Validación Multi-nivel - Calidad de datos en generación y carga

Estructura del Proyecto

ProyectoM2_MatiasGutierrez/

Scripts/

```
# Script generación 50kt registros (Avance 1)
--- 01_data_generation/
# 12 queries + optimización de índices (Avance 2)
--- 02_y_03_queries_optimization/
# DDL del Data Warehouse (Avance 3)
--- 04_dimensional_model/
# Pipeline ETL completo + script de consultas (Avance 3)
--- 05_etl_pipeline/
# Pipeline AMS setup + Simulador (Avance 4)
--- 06_aws_setup/
# Funciones Lambda (Avance 4)
--- Lambda_functions.py
```

Documentación/

```
--- README.pdf
# Guía general del proyecto
--- Fileetlogix_ER_Diagram.JPG
# Documento de entrega (Avance 1)
--- Análisis_del_modelo_proporcionado.pdf
# Documento de entrega (Avance 1)
--- Manual_Consultas_SQL.pdf
# Documento de entrega (Avance 2)
--- Análisis_Snowflake_ETL.pdf
# Documento de entrega (Avance 3)
--- aws_architecture_diagram.png
# Documento de entrega (Avance 4)
--- AMS_Análisis_Arquitectura.pdf
# Documento de entrega (Avance 4)
```

Características Destacadas

Generación de Datos Sintéticos Avanzada

- Distribuciones probabilísticas realistas
- Coherencia temporal garantizada
- Integridad referencial 100%

- Patrones operativos específicos para logística argentina

Pipeline ETL Robusto

- Estrategia UPSERT dual: MERGE nativo + fallback DELETE/INSERT
- Procesamiento por lotes para optimización de memoria
- Manejo explícito de tipos de datos entre sistemas
- Logging detallado para monitoreo y debugging

Herramientas de Verificación

- snowflake_verify_3: Interfaz interactiva para consultas
- Detección automática de columnas disponibles
- 10 opciones predefinidas para análisis comunes
- Modo SQL interactivo para consultas personalizadas

Optimización de Performance

- 12 índices estratégicos implementados y evaluados
- Análisis EXPLAIN ANALYZE para todas las queries
- Mejora selectiva en queries complejas (hasta 63.6%)
- Recomendaciones específicas basadas en métricas reales

Lecciones Aprendidas

Técnicas

- "Más índices ≠ mejor performance" - Evaluar relación costo-beneficio por query
- MERGE de Snowflake es la solución más eficiente para UPSERT
- Importancia del fallback en ingeniería de datos

- Manejo explícito de tipos de datos entre Pandas/Python/SQL

Arquitectónicas

- SCD Type 2 esencial para análisis histórico
- Arquitectura híbrida optimiza costos y performance
- Validación multi-fase garantiza calidad de datos
- Simulación local permite desarrollo sin dependencia de cloud

Próximos Pasos Recomendados

Inmediatos

- Implementar materialized views para métricas pre-calculadas
- Establecer dashboard ejecutivo en Tableau/Power BI
- Automatizar monitoreo de calidad de datos
- Implementar alertas proactivas para anomalies

Estratégicos

- Migración gradual a arquitectura AWS propuesta
- Implementación de machine learning para predictivos
- Expansión a otras regiones de Latinoamérica
- Integración con sistemas de telemetría vehicular

Autor

Matias Damian Gutierrez

Data Scientist

Email: matiasgutierrez2502@gmail.com

LinkedIn: [linkedin.com/in/matias-gutierrez/](https://www.linkedin.com/in/matias-gutierrez/)

